Trabajo 1: capas Medallion y streaming

Universidad	Universidad EAFIT
Programa	Maestría en Ciencias de los Datos y Analítica
Curso	SI7006/SI6003 Almacenamiento y Procesamiento de Grandes Datos, 2026
Profesor	Edwin Montoya (emontoya@eafit.edu.co)
Valor	15 % de la nota del curso
Modalidad	Equipos de 2 o 3 personas
Fecha de entrega	Viernes 23 de octubre de 2026, hasta las 23:59
Forma de entrega	Por Asignaciones (Trabajo1) en Eafit Interactiva, especificando todos los integrantes. Debe adjuntar un archivo especificando github del trabajo, link del video en Youtube.

1. Objetivo

Aplicar a los datos del Proyecto Integrador una arquitectura de capas Medallion con SQL en Amazon Athena (parte A) y construir un flujo de streaming distinto del visto en el laboratorio 5, con IoT Core, SQS, Lambda y DynamoDB (parte B). Ambas partes se sustentan en un video.

2. Condiciones

- Datos de la parte A: del proyecto integrador de uno de los integrantes, con un mínimo de 1.000.000 de filas. Si el conjunto tiene menos, se amplía con una técnica de aumento de datos basada en los datos del proyecto, que debe indicarse
- Datos de la parte B: sinteticos o de un proyecto integrador.
- Cuenta de AWS: basta con la de uno de los integrantes. Todo el trabajo puede realizarse con el plan gratuito.
- Condiciones eliminatorias: el trabajo debe cumplir las de la sección 7.

3. Parte A: capas Medallion

1. **Descripción.** Describir brevemente el conjunto de datos: qué es, de dónde proviene, qué tipos de datos tiene, cuántas filas tiene y cuánto pesa.
2. **Bronce.** Subir el archivo a Amazon S3 y crear en Athena una tabla externa sobre él, con todas las columnas como texto.
3. **Hallazgos.** Cuantificar con SQL los defectos de calidad de los datos (por ejemplo, filas repetidas, valores vacíos, fechas o valores inválidos) y presentarlos en una tabla de hallazgos.
4. **Plata.** Escribir al menos 3 reglas de calidad en SQL, justificadas con los hallazgos. Crear una tabla Iceberg con las filas válidas y otra con las filas rechazadas y su motivo. Los conteos deben cuadrar:
   filas de bronce = filas válidas + filas rechazadas.
5. **Oro.** Crear una tabla Iceberg con una agregación que responda una pregunta de negocio útil para el proyecto.
6. **Comparación.** Ejecutar la misma consulta sobre bronce, plata y oro, y registrar los bytes escaneados y el tiempo de respuesta de cada una, con una breve interpretación de la diferencia.

4. Parte B: streaming

Flujo: IoT Core → SQS → Lambda → DynamoDB.

1. Crear una regla de IoT Core que envíe los mensajes de un tema a una cola de SQS.
2. Crear una función Lambda que consuma la cola.

3. Crear una tabla de DynamoDB donde la función guarde los eventos, con una llave justificada.
4. Adaptar la función al esquema de los eventos utilizados: campos que llegan y forma de guardarlos.
5. Publicar al menos 10.000 eventos mediante la API de IoT Core, por ejemplo con la AWS CLI o con un script.
6. Dar cuenta de todos los eventos publicados: la cantidad publicada debe ser igual a la de eventos guardados en DynamoDB más la de eventos descartados (por ejemplo, los que no siguen el esquema), con el motivo del descarte. Medir el retraso entre el envío del evento y su llegada a DynamoDB (promedio y máximo).

5. Preguntas finales

Se responden en el video:

- **Parte A:** Si sus datos fueran mil veces mayores, ¿qué cambiarían?
- **Parte B:** ¿A partir de qué volumen dejarían esta forma de streaming y cuál usarían en su lugar? ¿Por qué?

6. Video

- Publicado en YouTube como no listado.
- Contenido: la descripción del conjunto de datos; el archivo en S3 y la tabla de bronce; la tabla de hallazgos; las reglas de calidad; las tablas de plata con sus conteos; la tabla de oro y la pregunta que responde; la comparación de bytes y tiempos; los recursos de la parte B creados en la consola; la función Lambda y la llave de DynamoDB con su justificación; la publicación de los eventos (mínimo 10.000), su llegada a DynamoDB, los conteos de eventos guardados y descartados, y el retraso medido; la consola de CloudFormation sin stacks; y las respuestas a las preguntas finales.
- No se requiere mostrar cada paso de la creación de los recursos: basta mostrarlos en la consola.
- Las tablas deben verse con claridad en pantalla.
- No deben mostrarse credenciales de AWS ni datos sensibles del proyecto.

Sugerencia: al terminar la grabación, borrar los recursos creados para conservar los créditos gratuitos de la cuenta.

7. Condiciones eliminatorias

El incumplimiento de cualquiera de las siguientes condiciones implica una calificación de **0** en el trabajo, sin importar la calidad del resto:

1. **Recursos creados manualmente.** Los recursos deben crearse manualmente en la consola de AWS, sin infraestructura como código (Serverless Framework, CloudFormation, Terraform u otras), con el propósito de que los estudiantes se familiaricen con la nube y con su consola. La evidencia es la consola de AWS CloudFormation sin ningún stack en la región de trabajo, mostrada en el video. Si la cuenta conserva stacks de los laboratorios, deben eliminarse antes de grabar.
2. **Duración.** El video dura máximo **10 minutos**.
3. **Participación de todos los integrantes.** Todos los integrantes del equipo, es decir, los que figuran en la entrega por Asignaciones del Trabajo 1 de Eafit Interactiva, hablan en el video y se ve su rostro mientras hablan.
4. **Entrega a tiempo.** El correo se envía antes de las 23:59 del viernes 23 de octubre de 2026. Una entrega tardía tiene calificación de 0.

8. Criterios de evaluación

Se aplican a los trabajos que cumplen las condiciones eliminatorias de la sección 7.

Bloque	Criterio	Puntos
Parte A	Descripción del conjunto de datos: qué es, de dónde proviene, tipos de datos y peso	3
	Conjunto de al menos 1.000.000 de filas, reales o aumentadas con la técnica indicada	2
	Bronce: archivo en S3 y tabla externa en Athena con las columnas como texto	3
	Tabla de hallazgos con los defectos cuantificados mediante SQL	5
	Plata: al menos 3 reglas de calidad en SQL, justificadas con los hallazgos	5
	Plata: tabla Iceberg con las filas válidas	3
	Plata: tabla Iceberg con las filas rechazadas y su motivo	3
	Plata: conteos que cuadran (bronce = válidas + rechazadas)	3
	Oro: tabla Iceberg con una agregación	3
	Oro: la agregación responde una pregunta útil para el proyecto	2
	Comparación: bytes escaneados de la misma consulta en las tres capas	3
	Comparación: tiempo de respuesta en las tres capas	3
	Comparación: interpretación de la diferencia	2
	Pregunta final: si los datos fueran mil veces mayores, ¿qué cambiarían?	5
Parte B	Regla de IoT Core que envía los mensajes de un tema a una cola de SQS	5
	Función Lambda que consume la cola	5
	Tabla de DynamoDB con una llave justificada	5
	Función adaptada al esquema de los eventos utilizados	5
	Publicación de al menos 10.000 eventos mediante la API de IoT Core	5
	Conteos que cuadran: eventos publicados = guardados en DynamoDB + descartados, con su motivo	5
	Retraso medido entre el envío y la llegada (promedio y máximo)	5
	Pregunta final: ¿a partir de qué volumen dejarían esta forma de streaming y cuál usarían?	5
Video	Exposición de la parte A: explicación clara del procedimiento y de los resultados	5
	Exposición de la parte B: explicación clara del flujo y de los resultados	5
	Legibilidad: tablas y consolas visibles con claridad en pantalla	5
Total		**100**